
Corrigé — Exercice 19

Statistiques

1) a) Coordonnées du point moyen G .

$$\bar{x} = \frac{1 + 2 + 3 + 4 + 5}{5} = 3.$$

$$\bar{y} = \frac{10 + 19 + 31 + 40 + 50}{5} = \frac{150}{5}.$$

$$G(3; 30)$$

1) b) Covariance et variance de x .

Écarts de x : $-2, -1, 0, 1, 2$; donc $V(x) = 2$.

Écarts de y : $-20, -11, 1, 10, 20$.

Produits : $40; 11; 0; 10; 40$, de somme 101.

$$V(x) = 2 \quad \text{cov}(x, y) = \frac{101}{5} = 20,2$$

1) c) Droite de régression de y en x .

$$a = \frac{20,2}{2} = 10,1.$$

$$b = 30 - 10,1 \times 3 = 30 - 30,3.$$

$$y = 10,1x - 0,3$$

1) d) Coefficient de corrélation.

$$V(y) = \frac{400 + 121 + 1 + 100 + 400}{5} = \frac{1022}{5} = 204,4, \text{ donc } \sigma_y \simeq 14,2969 \text{ et } \sigma_x \simeq 1,4142.$$

$$r = \frac{20,2}{1,4142 \times 14,2969}$$

$$r \simeq 0,9991$$

2) a) Nouveau point moyen.

$$\bar{x} = \frac{1 + 2 + 3 + 4 + 5 + 6}{6} = 3,5.$$

$$\bar{y} = \frac{10 + 19 + 31 + 40 + 50 + 20}{6} = \frac{170}{6} = \frac{85}{3}.$$

$$G'(3,5; 28,3333)$$

2) b) Nouvelle droite de régression.

$$\sum x_i y_i = 10 + 38 + 93 + 160 + 250 + 120 = 671.$$

$$\text{cov}(x, y) = \frac{671}{6} - 3,5 \times \frac{85}{3} = \frac{671}{6} - \frac{595}{6} = \frac{76}{6} \simeq 12,6667.$$

$$V(x) = \frac{35}{12} \simeq 2,9167, \text{ donc } a \simeq \frac{12,6667}{2,9167} \simeq 4,3429.$$

$$b \simeq 28,3333 - 4,3429 \times 3,5.$$

$$y \simeq 4,3429x + 13,1333$$

2) c) Nouveau coefficient de corrélation.

$V(y) \simeq 184,2222$, donc $\sigma_y \simeq 13,5728$.

$$r = \frac{12,6667}{1,7078 \times 13,5728}$$

$$r \simeq 0,5464$$

3) a) Comparaison des coefficients directeurs.

10,1 devient 4,3429.

⇒ Le coefficient directeur a été divisé par plus de deux : la droite s'est fortement couchée sous l'effet d'un seul point.

3) b) Comparaison des coefficients de corrélation.

0,9991 devient 0,5464.

⇒ La corrélation passe d'excellente à médiocre. Un r de 0,55 ne permet plus de valider un ajustement affine.

3) c) Sensibilité de la régression à une mesure erronée.

⇒ Une seule mesure fautive sur six suffit à ruiner l'ajustement : elle déplace le point moyen, réduit la covariance et fait chuter le coefficient de corrélation. C'est pourquoi il faut toujours tracer le nuage avant de calculer : le point (6 ; 20) saute aux yeux sur un graphique, alors qu'il se dissimule dans les sommes. La chute brutale de r est d'ailleurs le signal d'alarme qui invite à revenir aux données brutes.

4) a) Nouvelle droite avec la valeur corrigée $y_6 = 61$.

$$\bar{y} = \frac{10 + 19 + 31 + 40 + 50 + 61}{6} = \frac{211}{6} \simeq 35,1667.$$

$$\sum x_i y_i = 10 + 38 + 93 + 160 + 250 + 366 = 917, \text{ donc } \text{cov}(x, y) = \frac{917}{6} - 3,5 \times \frac{211}{6} = \frac{917 - 738,5}{6} = 29,75.$$

$$a = \frac{29,75}{2,9167} = 10,2 \text{ et } b \simeq 35,1667 - 10,2 \times 3,5.$$

$$y \simeq 10,2x - 0,5333$$

4) b) Nouveau coefficient de corrélation.

$V(y) \simeq 303,8056$, donc $\sigma_y \simeq 17,4300$.

$$r = \frac{29,75}{1,7078 \times 17,4300}$$

$$r \simeq 0,9994$$

4) c) Comparaison avec la question 1) et conclusion.

Coefficient directeur : 10,1 puis 10,2. Corrélation : 0,9991 puis 0,9994.

⇒ La correction rétablit exactement le modèle initial : le sixième point, une fois juste, confirme la droite au lieu de la détruire. On en retient que la régression n'est pas fragile par nature — elle l'est seulement face à une donnée fautive. Détecter et corriger une mesure aberrante vaut mieux que la retirer, car un point supplémentaire correct renforce l'ajustement.