
Corrigé — Exercice 21

Statistiques

QCM 1) Point par lequel passe toujours la droite de régression.

L'ordonnée à l'origine vaut $b = \bar{y} - a\bar{x}$; en remplaçant x par $\bar{x}$ dans $y = ax + b$, on obtient exactement $\bar{y}$.

⇒ Réponse b) : le point moyen G . C'est le contrôle systématique après avoir calculé a et b .

QCM 2) Coefficient directeur de la droite de régression.

Méthode : $a = \frac{\text{cov}(x, y)}{V(x)}$.

$$a = \frac{-6}{3} = -2$$

⇒ Réponse a) : -2 . La réponse c) multiplierait au lieu de diviser.

QCM 3) Encadrement de r .

$r = \frac{\text{cov}(x, y)}{\sigma_x \sigma_y}$, et l'on démontre que $|r| \leq 1$, avec égalité si et seulement si les points sont alignés.

⇒ Réponse b) : $-1 \leq r \leq 1$. La réponse a) oublie que r peut être négatif — c'est le cas d'une corrélation décroissante.

QCM 4) Retour à y après le changement de variable $z = \ln y$.

De $z = 0,5x + 2$ et $z = \ln y$, on tire $\ln y = 0,5x + 2$, puis, en composant par $\exp$:

$$y = e^{0,5x+2}$$

⇒ Réponse b). La réponse a) est précisément l'erreur classique : oublier de revenir à y .

V/F 1) Un r proche de 1 prouve que x est la cause de y .

r mesure une liaison **linéaire**, c'est-à-dire un alignement du nuage. Il ne dit rien du sens de cette liaison, ni de son origine.

Deux grandeurs peuvent être fortement corrélées parce qu'elles dépendent toutes deux d'une troisième, sans que l'une soit la cause de l'autre.

⇒ Faux. **Corrélation n'est pas causalité : c'est l'avertissement le plus important du chapitre.**

V/F 2) La droite de Mayer passe par le point moyen de la série.

La droite de Mayer joint $G_1(\bar{x}_1, \bar{y}_1)$ et $G_2(\bar{x}_2, \bar{y}_2)$, points moyens de deux groupes de même effectif $\frac{n}{2}$.

Le point moyen G de la série entière vérifie $\bar{x} = \frac{\bar{x}_1 + \bar{x}_2}{2}$ et $\bar{y} = \frac{\bar{y}_1 + \bar{y}_2}{2}$: G est le milieu de $[G_1 G_2]$.

⇒ Vrai. G appartient donc au segment $[G_1 G_2]$, et en particulier à la droite de Mayer.

V/F 3) Si $r = 0$, il n'existe aucune liaison entre x et y .

$r = 0$ signifie seulement qu'il n'y a aucune liaison *linéaire*. Une liaison d'un autre type peut parfaitement exister.

Contre-exemple : la série $x_i = -2, -1, 0, 1, 2$ et $y_i = 4, 1, 0, 1, 4$, c'est-à-dire $y = x^2$. On a $\bar{x} = 0$, et

$$\text{cov}(x, y) = \frac{1}{n} \sum x_i y_i - 0 = \frac{-8 - 1 + 0 + 1 + 8}{5} = 0, \text{ donc } r = 0.$$

Pourtant y est entièrement déterminé par x : la liaison est totale, mais quadratique.

⇒ Faux. C'est pourquoi on regarde toujours le nuage avant de conclure.

V/F 4) La variance $V(x)$ peut être négative.

$V(x) = \frac{1}{n} \sum_i (x_i - \bar{x})^2$ est une somme de carrés divisée par $n > 0$.

$\Rightarrow$ Faux. $V(x) \geq 0$ toujours, et $V(x) = 0$ uniquement lorsque tous les x_i sont égaux. Obtenir une variance négative signale une erreur de calcul : c'est un contrôle à faire systématiquement.